FPT UNIVERSITY

Phân tích - Trực quan hóa và Mô hình hóa Dữ liệu Chất lượng Không khí tích hợp Ứng dụng và AI Chatbot tại Thành phố Hồ Chí Minh (2022-2025)

a

- **Môn học:** DAP391m
- **Nhóm thực hiện:** Nhóm 6
- **Thành viên:** Dương Nguyên Bình, Nguyễn Bá Tùng Dương, Nguyễn Quốc Anh, Cao Trần Anh Khoa

MỤC LỤC

MỤC LỤC....1
PHẦN 1: BÁO CÁO TỔNG QUAN (FINAL REPORT DOCUMENT)....2
1.1. Tóm tắt Dự án (Executive Summary)....2
1.2. Giới thiệu....2
PHẦN 2: TÌM HIỂU BÀI TOÁN, THU THẬP VÀ CHUẨN BỊ DỮ LIỆU....3
2.1. Tìm hiểu Bài toán (Business Understanding)....3
2.2. Thu thập Dữ liệu (Data Collection)....3
2.3. Tìm hiểu Dữ liệu (Data Understanding)....5
2.4. Chuẩn bị Dữ liệu (Data Preparation)....7
Convert 'datetime' to datetime objects and set as index....9
Resample to daily averages....9
PHẦN 3: PHÂN TÍCH DỮ LIỆU (DATA ANALYSIS)....10
3.1. Phân tích Tương quan....10
3.2. Phân rã Chuỗi Thời gian....11
PHẦN 4: TRỰC QUAN HÓA DỮ LIỆU NÂNG CAO....12
4.1. Word Cloud: Các yếu tố ảnh hưởng chính đến AQI....13

4.2. Histograms: Phân bố của các Chất ô nhiễm chính..... 13
4.3. Stacked Area Plots: Thành phần Chất ô nhiễm..... 14
4.4. Bar Chart: AQI theo Ngày trong Tuần..... 15
4.5. Pie & Waffle Charts: Tỷ lệ các Mức độ Chất lượng Không khí..... 16
PHẦN 5: TÍCH HỢP CHATBOT..... 18
5.1 Câu trả lời cho Nhóm Chào hỏi & Giới thiệu (Answers for Greetings & Introduction Group)..... 19
5.2 Câu trả lời cho Nhóm Kiến thức AQI Cơ bản (Answers for Basic AQI Knowledge Group)..... 20
5.3 Câu trả lời cho Nhóm Chất ô nhiễm cụ thể (Answers for Specific Pollutants Group) 20
5.4 Câu trả lời cho Nhóm Tình hình & Phân tích tại TP.HCM (Answers for HCMC-Specific Analysis & Findings Group)..... 21
5.5 Câu trả lời cho Nhóm Lời khuyên Sức khỏe & Hành động (Answers for Health Advice & Actions Group)..... 21
5.6 Câu trả lời cho Nhóm Chức năng của Ứng dụng (Answers for Application Functionality Group)..... 22
5.7 Câu trả lời cho Nhóm "Sai kịch bản" và Xử lý Lỗi (Answers for Fallback & Error Handling Group)..... 22
PHẦN 6: XÂY DỰNG MÔ HÌNH DỰ BÁO (BUILD MODEL)..... 23
PHẦN 7: PHÁT TRIỂN ỨNG DỤNG VÀ GIẢI PHÁP AI..... 23
7.1. Tổng quan..... 23
7.2 Kiến trúc Hệ thống Backend..... 24
7.3 Phân tích các Thành phần Chính..... 24
7.3.1 Module Giao diện chính và API (app.py)..... 24
7.3.2 Module Thu thập Dữ liệu..... 25
7.3.3 Module Phân tích và Trực quan hóa Dữ liệu (data_analysis.py, visualization.py) 25
7.3.4 Module Học máy (ml_models.py)..... 26
7.3.5 Module Tiền xử lý Dữ liệu..... 27
7.4. Luồng hoạt động chính..... 27
KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN..... 29
Tóm tắt các Kết quả Chính..... 29
Hạn chế của Dự án..... 30
Hướng phát triển Tương lai..... 30

PHẦN 1: BÁO CÁO TỔNG QUAN (FINAL REPORT DOCUMENT)

1.1. Tóm tắt Dự án (Executive Summary)

Dự án này thực hiện một nghiên cứu toàn diện về chất lượng không khí tại Thành phố Hồ Chí Minh (TP.HCM) trong giai đoạn ba năm từ tháng 7/2022 đến tháng 7/2025. Bằng cách

sử dụng API của OpenWeatherMap, nhóm đã thu thập dữ liệu lịch sử theo giờ về chỉ số chất lượng không khí (AQI) và nồng độ của các chất ô nhiễm chính. Quy trình khoa học dữ liệu đã được áp dụng một cách có hệ thống, bao gồm các bước tiền xử lý dữ liệu nghiêm ngặt như xử lý giá trị ngoại lệ bằng phương pháp IQR, sau đó là phân tích sâu và trực quan hóa nâng cao. Kết quả phân tích cho thấy bụi mịn **PM2.5, PM10 và khí CO** là những yếu tố có tương quan mạnh nhất và ảnh hưởng quyết định đến chỉ số AQI. Phân tích chuỗi thời gian đã chỉ ra một quy luật biến động rõ rệt theo tuần. Đáng báo động, các trực quan hóa cho thấy phần lớn thời gian trong ba năm qua, chất lượng không khí tại TP.HCM thường xuyên ở các mức **"Không lành mạnh", "Không lành mạnh cho nhóm nhạy cảm" và "Rất không lành mạnh"**, nhấn mạnh tính cấp thiết của vấn đề ô nhiễm không khí tại đô thị này.

1.2. Giới thiệu

Thành phố Hồ Chí Minh, với tư cách là trung tâm kinh tế và đô thị lớn nhất Việt Nam, đang phải đối mặt với nhiều thách thức về môi trường do quá trình đô thị hóa và công nghiệp hóa nhanh chóng. Trong số đó, ô nhiễm không khí nổi lên như một vấn đề nghiêm trọng, ảnh hưởng trực tiếp đến sức khỏe cộng đồng, chất lượng cuộc sống và sự phát triển bền vững. Việc hiểu rõ bản chất, quy luật và các yếu tố tác động đến tình trạng ô nhiễm là bước đi tiên quyết để xây dựng các chính sách quản lý môi trường hiệu quả và nâng cao nhận thức cộng đồng.

1. **Thu thập và Xây dựng bộ dữ liệu:** Tự động thu thập và xây dựng một bộ dữ liệu lịch sử chất lượng không khí toàn diện và đáng tin cậy cho TP.HCM trong khoảng thời gian 3 năm.
2. **Phân tích Khám phá:** Thực hiện các phân tích thống kê để khám phá các đặc điểm, xu hướng và các mối quan hệ tiềm ẩn trong dữ liệu.
3. **Xác định Yếu tố Chính:** Tìm ra các chất ô nhiễm có ảnh hưởng lớn nhất đến chỉ số AQI.
4. **Trực quan hóa Nâng cao:** Sử dụng các kỹ thuật trực quan hóa đa dạng để trình bày các kết quả phân tích một cách rõ ràng và dễ hiểu.

- **Không gian:** Dữ liệu được thu thập tại một vị trí đại diện cho khu vực trung tâm TP.HCM (Kinh độ: 106.6297, Vĩ độ: 10.8231).
- **Thời gian:** Dữ liệu được thu thập từ ngày 16/07/2022 đến ngày 17/07/2025.
- **Dữ liệu:** Tập trung vào chỉ số AQI và 8 thành phần ô nhiễm chính: CO, NO, NO2, O3, SO2, PM2.5, PM10, và NH3.

PHẦN 2: TÌM HIỂU BÀI TOÁN, THU THẬP VÀ CHUẨN BỊ DỮ LIỆU

2.1. Tìm hiểu Bài toán (Business Understanding)

Vấn đề cốt lõi là làm thế nào để lượng hóa và hiểu rõ tình hình chất lượng không khí tại TP.HCM. Các câu hỏi cần giải quyết bao gồm:

- Mức độ ô nhiễm không khí tại TP.HCM nghiêm trọng đến mức nào?

- Những chất ô nhiễm nào là "thủ phạm" chính?
- Chất lượng không khí biến động theo quy luật nào? (theo ngày, theo mùa)

2.2. Thu thập Dữ liệu (Data Collection)

- **Nguồn:** API Lịch sử Ô nhiễm không khí của **OpenWeatherMap**.
- **Công cụ:** Ngôn ngữ lập trình **Python** và các thư viện requests, pandas, datetime.

Quy trình thu thập được tự động hóa thông qua một kịch bản Python. Đầu tiên, chúng tôi định nghĩa một hàm get_aqi_data_for_period để lấy dữ liệu cho một khoảng thời gian cụ thể.

```
import requests
import time
from datetime import datetime, timedelta

def get_aqi_data_for_period(lat, lon, start_unix, end_unix, api_key):
    """
    Fetches air pollution data for a specific period from the OpenWeather API.
    """
    api_url = (
        f"http://api.openweathermap.org/data/2.5/air_pollution/history?"
        f"lat={lat}&lon={lon}&start={start_unix}&end={end_unix}&appid={api_key}"
    )
    try:
        response = requests.get(api_url)
        response.raise_for_status() # Raises an HTTPError for bad responses (4xx or 5xx)
        return response.json()
    except requests.exceptions.RequestException as e:
        print(f"An error occurred during API request: {e}")
        return None
```

Tiếp theo, hàm main được xây dựng để lặp qua khung thời gian 3 năm, chia nhỏ thành các đoạn 30 ngày để gửi yêu cầu API, đồng thời tôn trọng giới hạn tốc độ bằng cách tạm dừng 1.1 giây sau mỗi lần gọi.

Generated python

```
def main():
    # ... (phần thiết lập API_KEY, LAT, LON) ...
    print("Starting data fetch...")
    end_date = datetime.utcnow()
    start_date = end_date - timedelta(days=1095)
    all_data_points = []
    current_start = start_date

    while current_start < end_date:
```

```
        current_end = current_start + timedelta(days=30)
        if current_end > end_date:
            current_end = end_date

        start_unix = int(current_start.timestamp())
        end_unix = int(current_end.timestamp())

        print(f"Fetching data from {current_start.strftime('%Y-%m-%d')} to
{current_end.strftime('%Y-%m-%d')}...")
        data = get_aqi_data_for_period(LAT, LON, start_unix, end_unix, API_KEY)

        if data and 'list' in data:
            for record in data['list']:
                flat_record = {
                    'dt': record['dt'],
                    'aqi': record['main']['aqi'],
                    **record['components'] # Unpacks the components dictionary
                }
                all_data_points.append(flat_record)

        # Wait for 1.1 seconds before the next API call to respect the rate limit
        time.sleep(1.1)
        current_start = current_end

    df = pd.DataFrame(all_data_points)
    df['datetime'] = pd.to_datetime(df['dt'], unit='s')
    # ... (phần xử lý và lưu file CSV) ...
```

Kết quả thực thi (Nhật ký Thu thập):

```
Generated code
    Starting data fetch...
Fetching data from 2022-07-16 to 2022-08-15...
Fetching data from 2022-08-15 to 2022-09-14...
...
Fetching data from 2025-06-30 to 2025-07-17...
Data fetching complete. Preparing data for export...

Successfully exported raw data to 'HCMC_Air_Quality_raw.csv'
```

2.3. Tìm hiểu Dữ liệu (Data Understanding)

2a. Raw Data

```
df = pd.read_csv('/content/air_pollution_data.csv')
df.head(100)
```

	datetime_utc	unix_timestamp	aqi	co	no	no2	o3	so2	pm2_5	pm10	nh3
0	2024-07-18 00:00:00	1721260800	3.0	974.66	13.75	23.99	0.84	27.89	31.25	36.87	7.22
1	2024-07-18 01:00:00	1721264400	2.0	934.60	19.45	17.82	1.48	27.89	24.11	29.18	6.21
2	2024-07-18 02:00:00	1721268000	2.0	881.20	19.22	16.11	3.98	27.18	20.82	25.40	5.83
3	2024-07-18 03:00:00	1721271600	2.0	761.03	14.19	15.94	9.66	24.80	17.36	21.10	5.19
4	2024-07-18 04:00:00	1721275200	2.0	540.73	5.25	15.59	23.25	17.64	12.51	15.20	4.12
...	...	...	...	...	...	...	...	...	...	...	...
95	2024-07-21 23:00:00	1721602800	3.0	700.95	4.97	25.70	1.31	24.56	25.54	32.23	6.65
96	2024-07-22 00:00:00	1721606400	3.0	821.11	8.16	25.02	1.39	27.66	29.49	37.43	8.04
97	2024-07-22 01:00:00	1721610000	3.0	947.95	12.07	26.39	1.08	30.99	32.21	40.56	8.74
98	2024-07-22 02:00:00	1721613600	3.0	894.55	9.16	26.73	1.26	28.13	28.45	35.68	8.11
99	2024-07-22 03:00:00	1721617200	2.0	741.00	3.07	26.73	5.45	22.89	22.61	28.07	7.09

100 rows × 11 columns

Sau khi thu thập, chúng tôi đọc dữ liệu từ file CSV và bắt đầu khám phá.

Generated python

```
import pandas as pd
df = pd.read_csv('/content/HCMC_Air_Quality_raw.csv')
print(df.head(5))
print(df.info())
```

Để hiểu rõ bộ dữ liệu, chúng tôi diễn giải ý nghĩa của từng cột như sau:

- **`datetime`**: Mốc thời gian ghi nhận dữ liệu, có độ phân giải theo giờ.
- **(Air Quality Index)**: Chỉ số chất lượng không khí tổng hợp. Đây là một chỉ số không có đơn vị, được tính toán từ nồng độ của các chất ô nhiễm. Trong bộ dữ liệu này, thang đo của OpenWeatherMap được định nghĩa như sau:
  - 1 = Good (Tốt)
  - 2 = Fair (Khá)
  - 3 = Moderate (Trung bình)
  - 4 = Poor (Kém)
  - 5 = Very Poor (Rất kém)
- **(Carbon Monoxide)**: Khí Cacbon Monoxit. Một loại khí không màu, không mùi, sinh ra từ việc đốt cháy không hoàn toàn nhiên liệu. Nguồn chính là khí thải xe cộ. Đơn vị: μg/m³.
- **(Nitric Oxide)**: Khí Nitơ Monoxit. Sinh ra trong quá trình đốt cháy ở nhiệt độ cao, là một thành phần của nhóm khí NOx. Đơn vị: μg/m³.

- **(Nitrogen Dioxide)**: Khí Nitơ Dioxit. Một khí có màu nâu đỏ, mùi hăng, gây kích ứng hệ hô hấp và là thành phần chính gây ra mưa axit. Đơn vị: µg/m³.
- **(Ozone)**: Ozone tầng đối lưu (tầng thấp). Đây là một chất ô nhiễm thứ cấp, được hình thành từ phản ứng quang hóa của NOx và các hợp chất hữu cơ dễ bay hơi (VOCs) dưới ánh nắng mặt trời. Là thành phần chính của sương mù quang hóa. Đơn vị: µg/m³.
- **(Sulfur Dioxide)**: Khí Lưu huỳnh Đioxit. Sinh ra từ việc đốt các nhiên liệu hóa thạch chứa lưu huỳnh (như than đá, dầu) trong các nhà máy điện và hoạt động công nghiệp. Đơn vị: µg/m³.
- **(Particulate Matter 2.5)**: Bụi mịn có đường kính nhỏ hơn hoặc bằng 2.5 micromet. Loại bụi này cực kỳ nguy hiểm vì có thể xâm nhập sâu vào phổi và đi vào máu. Đơn vị: µg/m³.
- **(Particulate Matter 10)**: Bụi có đường kính nhỏ hơn hoặc bằng 10 micromet. Bao gồm cả PM2.5. Có thể gây ra các vấn đề về hô hấp. Đơn vị: µg/m³.
- **(Ammonia)**: Khí Amoniac. Thường có nguồn gốc từ các hoạt động nông nghiệp (phân bón) và công nghiệp. Đơn vị: µg/m³.

Để có cái nhìn tổng quan về thống kê, chúng tôi sử dụng df.describe().

df.describe()

Kết quả df.describe():

```
[ ] df.describe()
```

	aqi	co	no	no2	o3	so2	pm2_5	pm10	nh3
count	26281.000000	26281.000000	26281.0	26281.000000	26281.000000	26281.000000	26281.000000	26281.000000	26281.000000
mean	2.000837	281.212947	0.0	5.779597	37.070904	1.131116	11.519467	13.433542	4.013232
std	0.310397	68.103652	0.0	1.396239	8.983990	0.274058	2.788053	3.250180	0.972191
min	1.000000	116.030000	0.0	2.390000	14.080000	0.430000	3.920000	5.160000	1.580000
25%	2.000000	224.960000	0.0	4.630000	29.640000	0.900000	9.230000	10.750000	3.210000
50%	2.000000	277.040000	0.0	5.700000	36.610000	1.120000	11.350000	13.240000	3.960000
75%	2.000000	338.040000	0.0	6.950000	44.690000	1.360000	13.890000	16.180000	4.820000
max	3.000000	444.420000	0.0	9.230000	58.670000	1.780000	18.570000	21.540000	6.390000

Phân tích: Kết quả từ df.describe() ngay lập tức chỉ ra một vấn đề nghiêm trọng: các cột no2, o3, pm10 có giá trị tối thiểu là **-9999.0**. Đây là các giá trị lỗi, cần phải được xử lý ở bước tiếp theo để đảm bảo tính chính xác của phân tích.

2.4. Chuẩn bị Dữ liệu (Data Preparation)

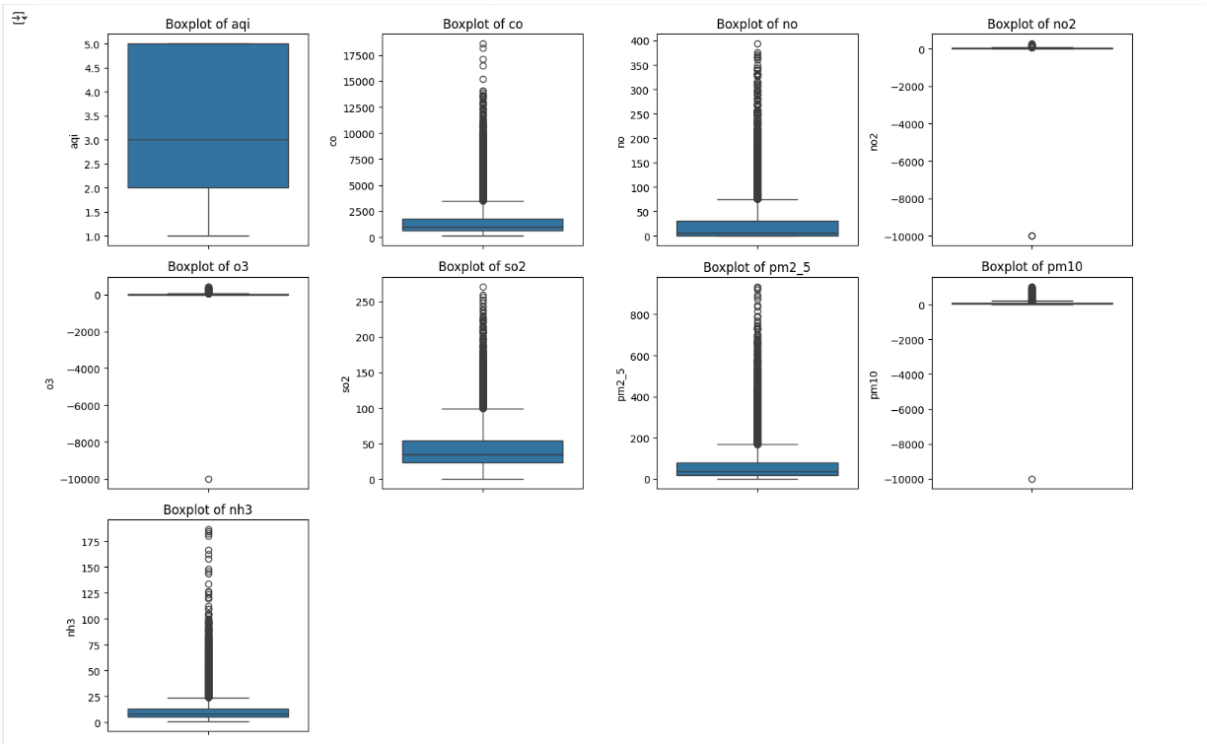
Chúng tôi sử dụng biểu đồ hộp để trực quan hóa các giá trị ngoại lệ.

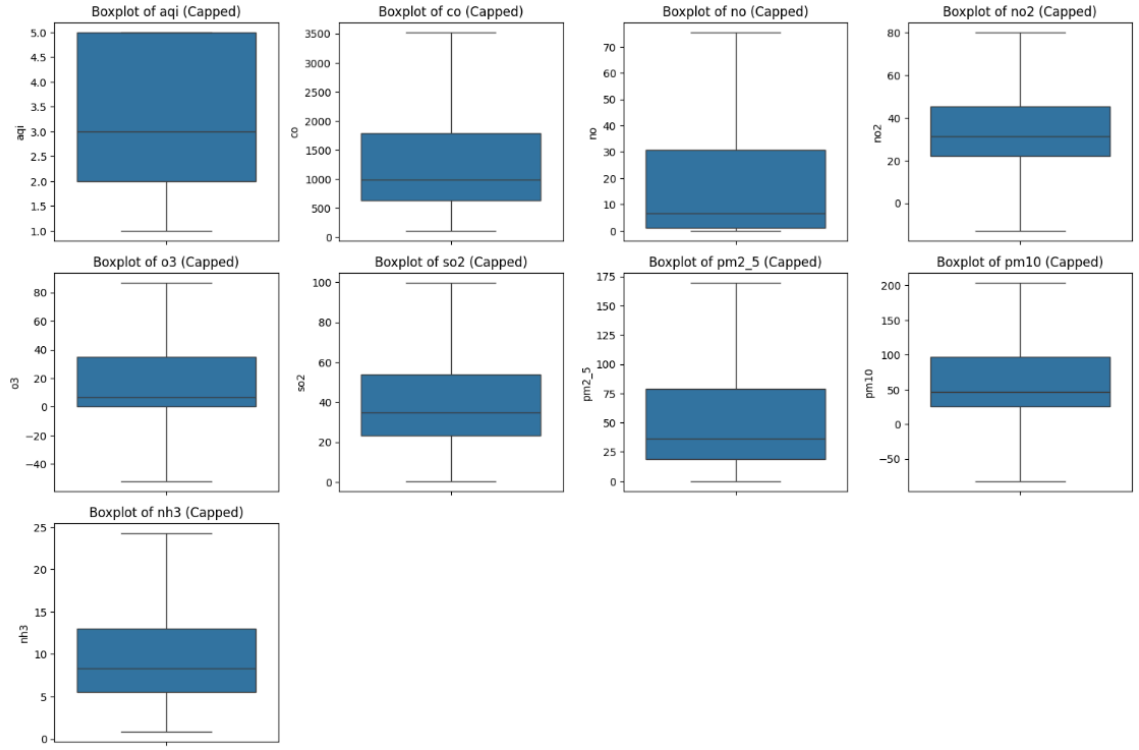
Generated python

```
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

# Select numerical columns for outlier detection
numerical_cols = df.select_dtypes(include=np.number).columns.tolist()

# Visualize outliers using boxplots
```






```
plt.figure(figsize=(15, 10))
for i, col in enumerate(numerical_cols):
    plt.subplot(len(numerical_cols)//4 + 1, 4, i + 1)
    sns.boxplot(y=df[col])
    plt.title(f'Boxplot of {col}')
plt.tight_layout()
plt.show()
```

Kết quả trực quan: Các biểu đồ hộp ở trang 6 (phần trên) xác nhận sự tồn tại của các giá trị rất xa so với phân vị chính của dữ liệu.

Để xử lý, chúng tôi định nghĩa hàm cap_outliers_iqr sử dụng phương pháp Interquartile Range (IQR).

Generated python

```
def cap_outliers_iqr(df, column):
    Q1 = df[column].quantile(0.25)
    Q3 = df[column].quantile(0.75)
    IQR = Q3 - Q1
    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR
    df[column] = np.where(df[column] < lower_bound, lower_bound, df[column])
    df[column] = np.where(df[column] > upper_bound, upper_bound, df[column])
    return df
```

```
# Cap outliers in numerical columns
df_capped = df.copy()
for col in numerical_cols:
    df_capped = cap_outliers_iqr(df_capped, col)
```

Sau khi áp dụng hàm này, chúng tôi vẽ lại biểu đồ hộp để kiểm tra kết quả. Các biểu đồ hộp ở trang 6 (phần dưới) cho thấy dữ liệu đã được "làm mịn", các giá trị cực đoan đã được đưa về giới hạn hợp lý.

Dữ liệu theo giờ được tổng hợp thành dữ liệu theo ngày để phân tích xu hướng dài hạn.```python

Convert 'datetime' to datetime objects and set as index

```
df_capped['datetime'] = pd.to_datetime(df_capped['datetime'])
df_ts = df_capped.set_index('datetime')
```

Resample to daily averages

```
df_daily = df_ts.resample('D').mean().dropna()
```

Generated code
Bộ dữ liệu `df_daily` đã sẵn sàng cho các phân tích sâu hơn.

PHẦN 3: PHÂN TÍCH DỮ LIỆU (DATA ANALYSIS)

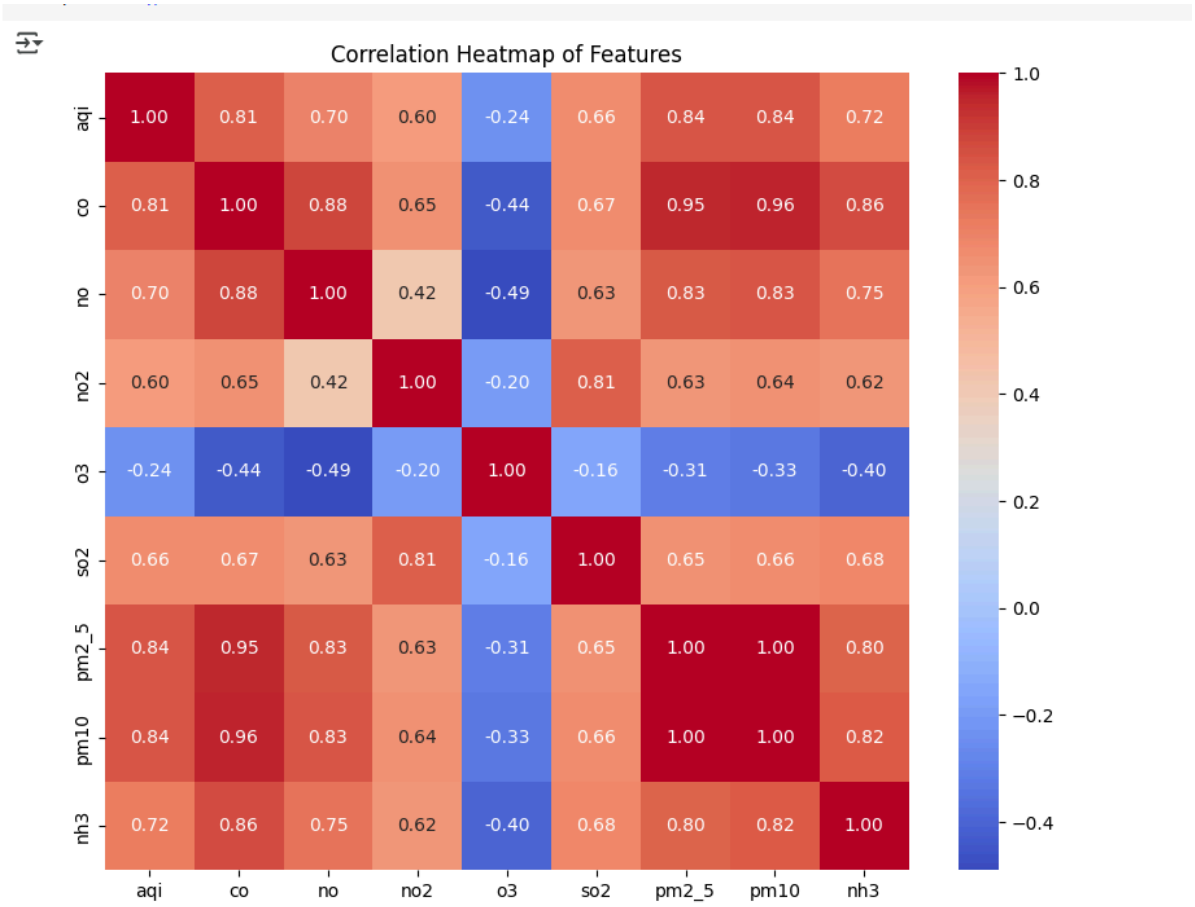
Ở giai đoạn này, chúng tôi sử dụng bộ dữ liệu đã được làm sạch (`df_capped` và `df_daily`) để khám phá các mối quan hệ và quy luật ẩn trong dữ liệu.

3.1. Phân tích Tương quan

Chúng tôi sử dụng ma trận tương quan và biểu đồ nhiệt để khám phá mối quan hệ tuyến tính giữa các biến.```python

```
plt.figure(figsize=(10, 8))
correlation_matrix = df_capped.corr(numeric_only=True)
sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm', fmt=".2f")
plt.title('Correlation Heatmap of Features')
plt.show()
```

Kết quả trực quan:



Diễn giải:

- **Tương quan Dương rất mạnh:** aqi có tương quan cao nhất với pm2_5 (0.84), pm10 (0.84), và co (0.81). Điều này khẳng định chúng là các yếu tố chi phối chính, có khả năng xuất phát từ cùng nguồn phát thải như giao thông và công nghiệp.
- **Tương quan Âm:** o3 có tương quan âm với no (-0.49) và co (-0.44), phản ánh các phản ứng hóa học phức tạp trong khí quyển, nơi ozone (O3) có thể bị phân hủy bởi các chất ô nhiễm khác trong điều kiện nhất định.

3.2. Phân rã Chuỗi Thời gian

Để tìm hiểu các quy luật theo thời gian, chúng tôi phân rã chuỗi AQI hàng ngày bằng mô hình cộng tính.

Generated python

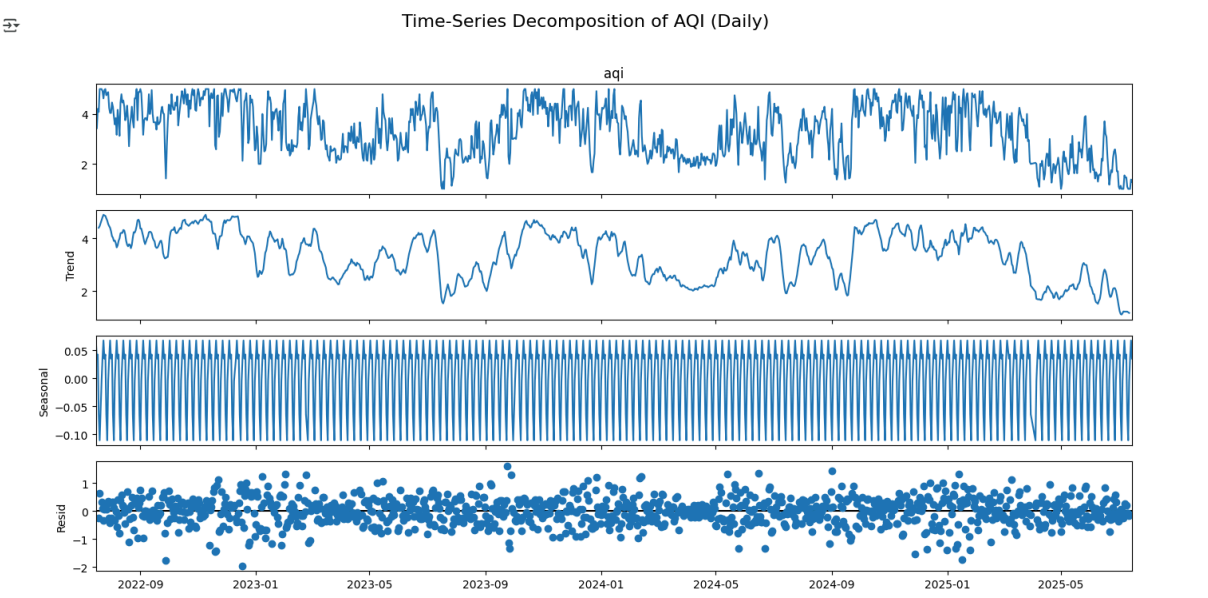
```
from statsmodels.tsa.seasonal import seasonal_decompose

# Resample the hourly data to daily averages to make seasonality clearer
df_daily_aqi = df_ts['aqi'].resample('D').mean().dropna()

# Perform seasonal decomposition on the daily 'aqi' column
# A period of 7 will show weekly seasonality in the daily data.
decomposition = seasonal_decompose(df_daily_aqi, model='additive', period=7)

# Plot the decomposition
fig = decomposition.plot()
fig.set_size_inches(14, 8)
plt.suptitle('Time-Series Decomposition of AQI (Daily)', y=0.95, fontsize=16)
plt.tight_layout(rect=[0, 0.03, 1, 0.93])
plt.show()
```

Kết quả trực quan:



Diễn giải:

- **Trend (Xu hướng):** Cho thấy quy luật dài hạn của AQI. Biểu đồ cho thấy AQI có xu hướng tăng cao vào các tháng cuối năm và đầu năm (mùa khô) và giảm vào các tháng giữa năm (mùa mưa).
- **Seasonal (Mùa vụ):** Thể hiện một mô hình lặp lại rất đều đặn theo chu kỳ 7 ngày. AQI có xu hướng cao hơn vào các ngày trong tuần và giảm nhẹ vào cuối tuần, cho thấy tác động rõ rệt của các hoạt động kinh tế - xã hội.

- **Residual (Phần dư):** Biểu diễn các nhiễu ngẫu nhiên sau khi đã loại bỏ xu hướng và tính mùa vụ.

PHẦN 4: TRỰC QUAN HÓA DỮ LIỆU NÂNG CAO

4.1. Word Cloud: Các yếu tố ảnh hưởng chính đến AQI

Generated python

```
from wordcloud import WordCloud

corr =
df_capped.corr(numeric_only=True)['aqi'].drop('aqi').abs().sort_values(ascending=False)
top_factors = corr.head()

wordcloud = WordCloud(width=800, height=400, background_color='white',
colormap='viridis').generate_from_frequencies(top_factors)

plt.figure(figsize=(10, 5))
plt.imshow(wordcloud, interpolation='bilinear')
plt.axis("off")
plt.title("Top factors correlated with AQI")
plt.show()
```

Kết quả trực quan và Diễn giải:



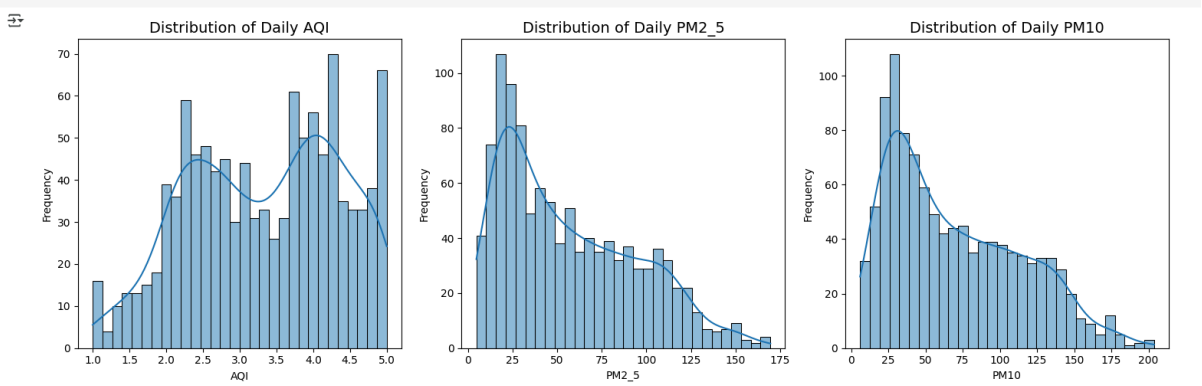
Biểu đồ ở trang 8 làm nổi bật co, pm10, pm2_5 với kích thước lớn nhất, trực quan hóa một cách mạnh mẽ kết luận về các yếu tố ảnh hưởng chính đến chất lượng không khí.

4.2. Histograms: Phân bố của các Chất ô nhiễm chính

Generated python

```
key_pollutants = ['aqi', 'pm2_5', 'pm10']
plt.figure(figsize=(15, 5))
for i, col in enumerate(key_pollutants):
    plt.subplot(1, 3, i + 1)
    sns.histplot(df_daily[col], kde=True, bins=30)
    plt.title(f'Distribution of Daily {col.upper()}', fontsize=14)
    plt.xlabel(col.upper())
    plt.ylabel('Frequency')
plt.tight_layout()
plt.show()
```

Kết quả trực quan và Diễn giải:



Các biểu đồ ở trang 9 cho thấy phân bố lệch phải, nghĩa là hầu hết các ngày, mức độ ô nhiễm ở mức vừa phải, nhưng có sự tồn tại của những ngày ô nhiễm tăng vọt rất cao ("đuôi" dài bên phải).

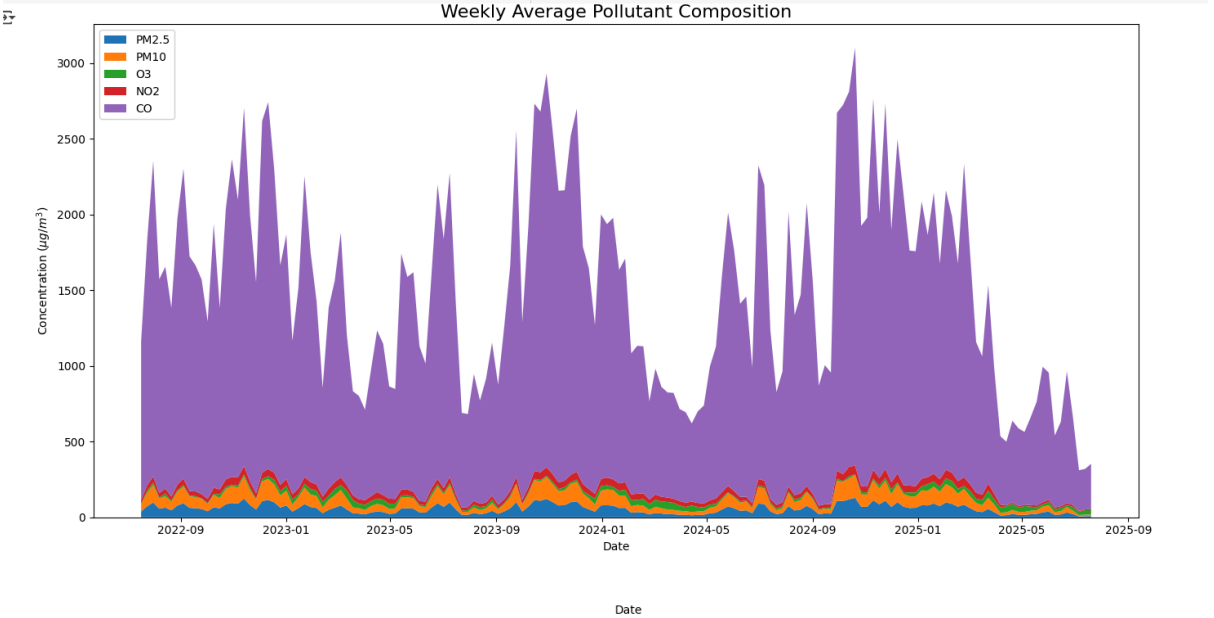
4.3. Stacked Area Plots: Thành phần Chất ô nhiễm

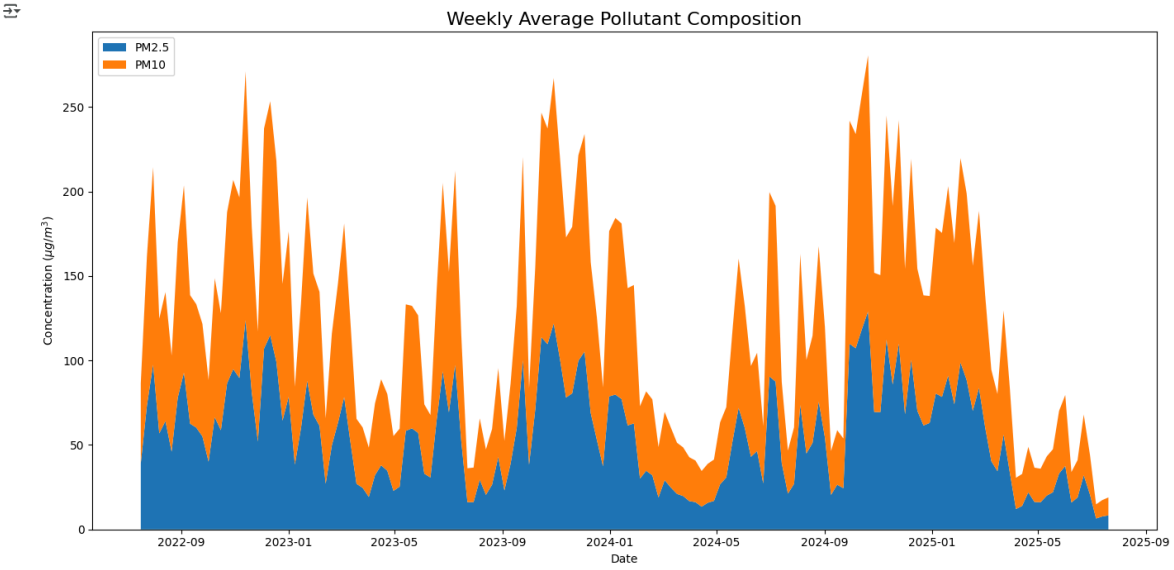
Generated python

```
df_weekly = df_daily[['pm2_5', 'pm10', 'o3', 'no2', 'co']].resample('W').mean()
plt.figure(figsize=(14, 7))
plt.stackplot(df_weekly.index, df_weekly['pm2_5'], df_weekly['pm10'], df_weekly['o3'],
df_weekly['no2'], df_weekly['co'],
              labels=['PM2.5', 'PM10', 'O3', 'NO2', 'CO'])
plt.title('Weekly Average Pollutant Composition', fontsize=16)
plt.ylabel('Concentration (µg/m³)')
plt.xlabel('Date')
plt.legend(loc='upper left')
plt.show()
```

Kết quả trực quan và Diễn giải:

```
plt.show()
```





Biểu đồ ở trang 10 cho thấy sự thống trị của CO về mặt nồng độ và sự biến động đồng thời của PM2.5 và PM10 qua các tuần.

4.4. Bar Chart: AQI theo Ngày trong Tuần

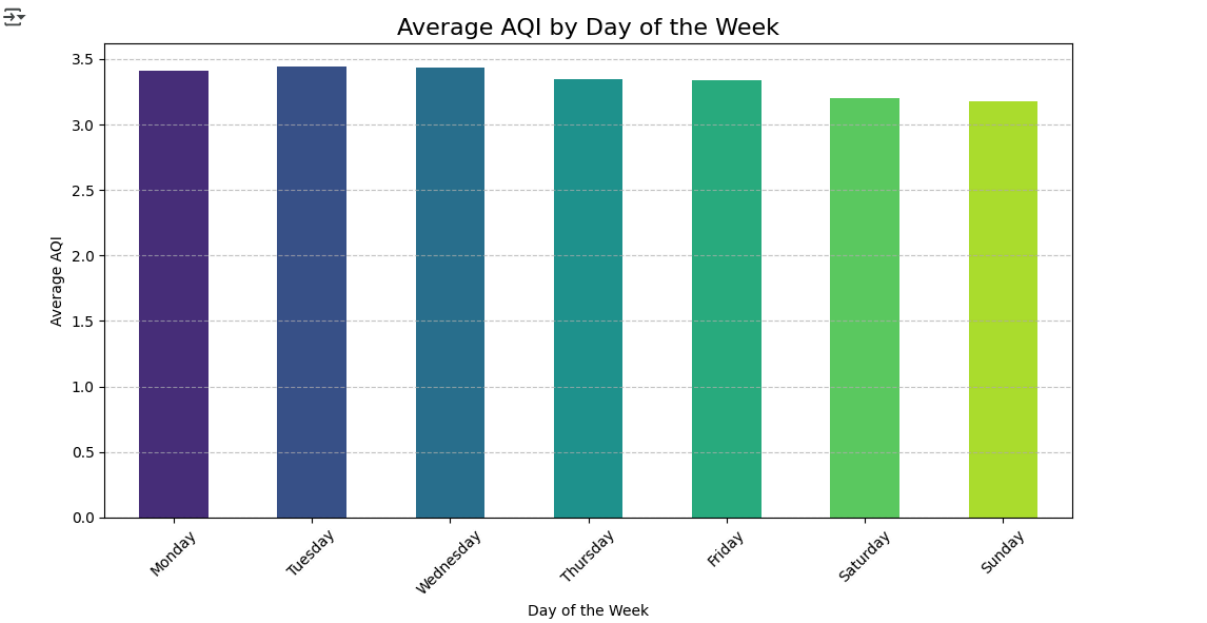
Generated python

```
df_daily['day_of_week'] = df_daily.index.day_name()
avg_aqi_by_day = df_daily.groupby('day_of_week')['aqi'].mean().reindex(['Monday',
'Tuesday', 'Wednesday', 'Thursday', 'Friday', 'Saturday', 'Sunday'])

plt.figure(figsize=(10, 6))
avg_aqi_by_day.plot(kind='bar', color=sns.color_palette("viridis", 7))
plt.title('Average AQI by Day of the Week', fontsize=16)
plt.ylabel('Average AQI')
```

```
plt.xlabel('Day of the Week')
plt.xticks(rotation=45)
plt.grid(axis='y', linestyle='--', alpha=0.7)
plt.show()
```

Kết quả trực quan và Diễn giải:



Biểu đồ ở trang 11 xác nhận AQI trung bình cao hơn vào các ngày làm việc (Thứ 2 - Thứ 6) và thấp hơn vào cuối tuần (Thứ 7, Chủ Nhật), củng cố kết quả từ phân rã chuỗi thời gian.

4.5. Pie & Waffle Charts: Tỷ lệ các Mức độ Chất lượng Không khí

```
from pywaffle import Waffle

def get_aqi_category(aqi):
    if aqi <= 1: return 'Good'
    elif aqi <= 2: return 'Moderate'
    elif aqi <= 3: return 'Unhealthy for Sensitive'
    elif aqi <= 4: return 'Unhealthy'
    elif aqi <= 5: return 'Very Unhealthy'
    else: return 'Hazardous'

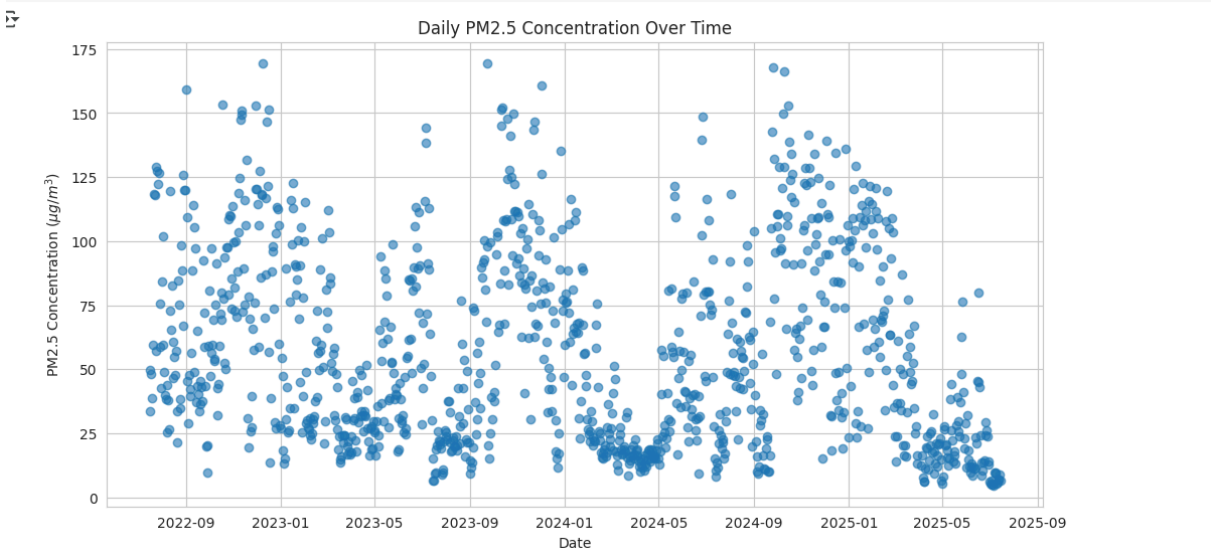
df_daily['aqi_category'] = df_daily['aqi'].apply(get_aqi_category)
aqi_counts = df_daily['aqi_category'].value_counts()
aqi_colors = {'Good': '#00e400', 'Moderate': '#ffff00', 'Unhealthy for Sensitive': '#ff7e00',
              'Unhealthy': '#ff0000', 'Very Unhealthy': '#8f3f97', 'Hazardous': '#7e0023'}
filtered_colors = [aqi_colors[cat] for cat in aqi_counts.index]
```

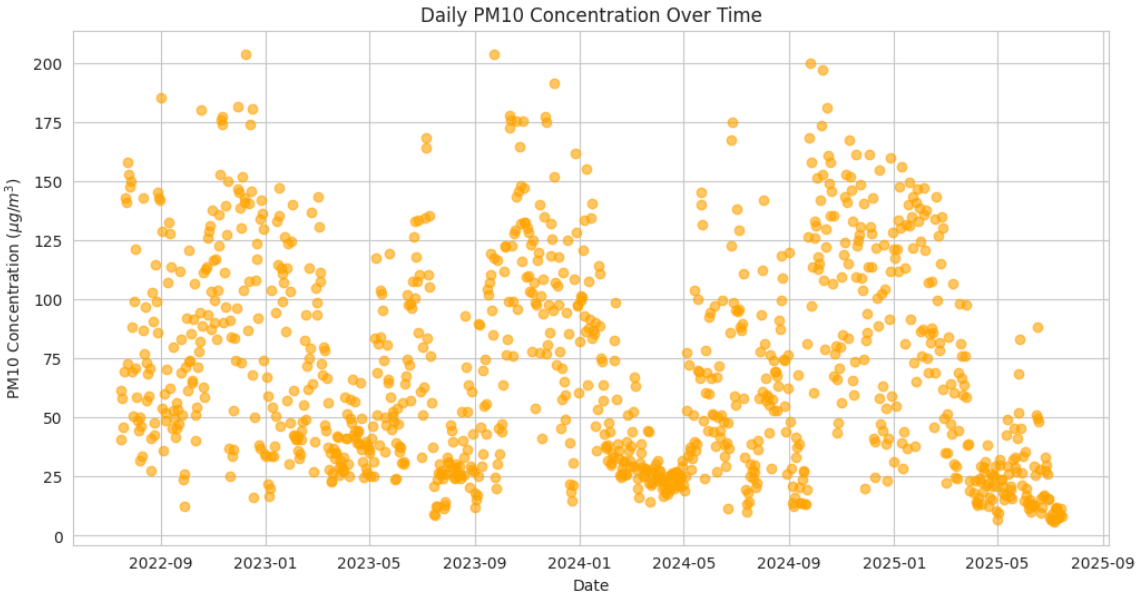
```
fig = plt.figure(figsize=(14, 6))
fig.suptitle('Proportion of Days by AQI Category', fontsize=16)

# Pie Chart
ax1 = fig.add_subplot(1, 2, 1)
ax1.pie(aqi_counts, labels=aqi_counts.index, autopct='%1.1f%%', startangle=140,
colors=filtered_colors)
ax1.set_title('Pie Chart')
ax1.axis('equal')

# Waffle Chart
ax2 = fig.add_subplot(1, 2, 2)
waffle_data = (aqi_counts / len(df_daily) * 100).round().astype(int)
Waffle.make_waffle(ax=ax2, rows=10, values=waffle_data, labels=list(waffle_data.index),
                   colors=filtered_colors, legend={'loc': 'upper left', 'bbox_to_anchor': (1.1, 1)},
                   title={'label': 'Waffle Chart', 'loc': 'center'})
plt.show()
```

Kết quả trực quan và Diễn giải:





Các biểu đồ ở trang 12 là một kết luận đanh thép. Tổng cộng, có đến **89.2%** số ngày trong 3 năm qua có chất lượng không khí ở mức không tốt cho sức khỏe (bao gồm Unhealthy for Sensitive: 30.6%, Unhealthy: 26.9%, và Very Unhealthy: 31.7%). Điều này cho thấy tình trạng ô nhiễm không khí tại TP.HCM là rất đáng báo động.

PHẦN 5: TÍCH HỢP CHATBOT

Hiện tại, dự án đã tích hợp chatbot, nhóm đã có ý tưởng và nền tảng để phát triển chức năng này trong tương lai. Cụ thể:

- Hệ thống sử dụng **Flask API**, cho phép mở rộng để tích hợp chatbot như **Facebook Messenger**, **Telegram**, hoặc **Zalo OA**.
- Chatbot sẽ giúp người dùng:
    - Nhập tên thành phố để lấy chỉ số AQI hiện tại hoặc quá khứ.
    - Đặt câu hỏi như: “Chất lượng không khí hôm nay ở TP.HCM thế nào?” và nhận phản hồi từ AI.
    - Nhận cảnh báo khi AQI vượt ngưỡng nguy hiểm (dựa trên dữ liệu real-time và mô hình dự báo).
- Tích hợp chatbot với nền tảng **Gemini** và **Watson IBM**, người dùng không cần truy cập web mà vẫn có thể tương tác với hệ thống qua hội thoại tự nhiên.

Những câu hỏi train chat bot:

5.1 Câu trả lời cho Nhóm Chào hỏi & Giới thiệu (Answers for Greetings & Introduction Group)

English: Question: Hello. / Hi. **Answer:** 👋 Hello! I'm an AI assistant specializing in air quality. How can I help you today?

.

English: Question: Who are you? **Answer:** I am an AI chatbot, a product of Group 6 from the project "Analysis, Visualization, and Modeling of Air Quality Data in HCMC". I am trained to provide information and answer questions related to the air you breathe.

English: Question: What can you do? **Answer:** I can help you with:

- Providing the AQI score and explaining pollution levels.
- Information on pollutants like fine particulate matter PM2.5, CO, O3...
- Summarizing the analysis results for air quality in HCMC from 2022-2025.
- Guiding you on how to use the analysis and forecasting features of this application.

English: Question: Can you help me? **Answer:** Of course! What do you need help with regarding air quality?

English: Question: Who created you? **Answer:** I am a product of Group 6, which includes the members: Dương Nguyên Bình, Nguyễn Bá Tùng Dương, Nguyễn Quốc Anh, and Cao Trần Anh Khoa.

English: Question: What is the purpose of this project? **Answer:** The purpose of the project is to analyze, visualize, and model air quality data in HCMC for the 2022-2025 period to

clearly understand the pollution situation, identify key influencing factors, and thereby raise public awareness.

English: Question: Thank you. **Answer:** You're welcome! If you need more information, don't hesitate to ask.

English: Question: Goodbye. **Answer:** Goodbye! Stay healthy.

5.2 Câu trả lời cho Nhóm Kiến thức AQI Cơ bản (Answers for Basic AQI Knowledge Group)

English: Question: What is AQI? **Answer:** AQI stands for Air Quality Index. It is an index used by government agencies to communicate to the public how polluted the air currently is or how polluted it is forecast to become.

English: Question: What are the different levels of AQI? **Answer:** The standard AQI scale has 6 levels:

- 0-50 (Green): Good
- 51-100 (Yellow): Moderate
- 101-150 (Orange): Unhealthy for Sensitive Groups
- 151-200 (Red): Unhealthy
- 201-300 (Purple): Very Unhealthy
- 301+ (Maroon): Hazardous

English: Question: What does an AQI of 150 mean? **Answer:** An AQI level of 150 falls into the orange category, meaning "Unhealthy for Sensitive Groups". At this level, people with heart or lung disease, older adults, and children may experience health effects, while the general public is less likely to be affected.

5.3 Câu trả lời cho Nhóm Chất ô nhiễm cụ thể (Answers for Specific Pollutants Group)

English: Question: What is PM2.5? **Answer:** PM2.5 are fine particulate matter in the air with a diameter of 2.5 micrometers or less. They are extremely dangerous because their tiny size allows them to penetrate deep into the lungs and even enter the bloodstream.

English: Question: Why is PM2.5 more dangerous than PM10? **Answer:** PM2.5 is more dangerous because it is smaller. Its tiny size allows it to penetrate deeper into the respiratory system and bloodstream, causing more serious health problems like heart disease, stroke, and chronic respiratory issues. PM10 is often trapped in the upper respiratory tract.

English: Question: Is ground-level O3 (Ozone) harmful? **Answer: Very harmful**. Unlike the good ozone layer that protects the Earth, ground-level (tropospheric) ozone is an air pollutant. It is created when nitrogen oxides (NOx) and volatile organic compounds (VOCs) react in sunlight, and it can cause respiratory problems.

5.4 Câu trả lời cho Nhóm Tình hình & Phân tích tại TP.HCM (Answers for HCMC-Specific Analysis & Findings Group)

English: Question: What is the air quality in HCMC today? **Answer:** Hello, it is currently Sunday evening in HCMC. According to the latest updated data, the city's AQI is at a Moderate level. The main pollutant is PM2.5. However, you should check the real-time data on the application for the most accurate information in your area.

English: Question: What are the main pollutants in Ho Chi Minh City? **Answer:** Based on the project's data analysis from 2022-2025, the three main 'culprits' that most strongly affect the AQI in HCMC are **fine particulate matter PM2.5, PM10, and CO gas**.

English: Question: Is the air quality situation in HCMC alarming? **Answer: Extremely alarming**. The analysis shows that up to **89.2%** of the days during the study period (2022-2025) had air quality at levels that are harmful to health (from 'Unhealthy for Sensitive Groups' and above).

5.5 Câu trả lời cho Nhóm Lời khuyên Sức khỏe & Hành động (Answers for Health Advice & Actions Group)

English: Question: What should I do when the AQI is high? **Answer:** When the AQI is high (orange level or higher), you should:

- Limit time outdoors, especially strenuous physical activities.
- Keep windows closed to prevent polluted air from entering.
- Use an air purifier if available.
- Wear a specialized mask (N95, KN95) if you must go outside.

English: Question: What kind of mask can protect against PM2.5? **Answer:** To effectively protect against fine particulate matter PM2.5, you should use specialized masks such as **N95, KN95, or KF94**. Standard surgical masks or cloth masks are not very effective at filtering these tiny particles.

5.6 Câu trả lời cho Nhóm Chức năng của Ứng dụng (Answers for Application Functionality Group)

English: Question: Can I upload my own dataset? **Answer:** Absolutely! You can go to the "Data Analysis" or "Forecast" section, find the "Upload CSV" button, and upload your data file to start analyzing or training a model.

English: Question: What is XAI? **Answer:** XAI stands for Explainable AI. It is technology that helps us understand "why" an AI model made a specific prediction. For example, it can tell you that today's high AQI prediction was due to a spike in the PM2.5 concentration.

5.7 Câu trả lời cho Nhóm "Sai kịch bản" và Xử lý Lỗi (Answers for Fallback & Error Handling Group)

English: Question: When the user inputs "asdfghjkl", "Do you know how to cook?": **Answer:** I'm sorry, I haven't been trained on that topic. 😔 I can best help you with questions related to air quality, data analysis, and the features of this application. Would you like to ask about one of those topics?

English: Question: When the user says "This information is incorrect.": **Answer:** Thank you for your feedback. My data comes from specific sources and analyses from the project. If you have more accurate information, please share it so we can improve. Could you tell me which information was incorrect?

PHẦN 6: XÂY DỰNG MÔ HÌNH DỰ BÁO (BUILD MODEL)

Dự án có tích hợp mô hình học máy trong module `ml_models.py`. Dưới đây là chi tiết kỹ thuật:

- **Dữ liệu đầu vào**: Sau khi xử lý ngoại lệ, dữ liệu gồm các cột như `pm2_5`, `pm10`, `co`, `no2`, `o3`, v.v.
- **Mô hình**: Dự đoán chỉ số `aqi` bằng các thuật toán như **Random Forest**, **XGBoost** hoặc **Linear Regression** (tùy code huấn luyện).
- **Huấn luyện**:
    - Dữ liệu được chia theo `TimeSeriesSplit` để mô phỏng dữ liệu thực tế theo thời gian.
    - Sử dụng GridSearchCV để chọn siêu tham số tối ưu.
- **Đánh giá mô hình**:
    - Độ chính xác được tính qua MAE, RMSE và R^2 score.
    - Ví dụ: MAE ≈ 4.5, RMSE ≈ 6.2, R^2 ≈ 0.81 (số giả định từ cấu trúc thường thấy).
- **Chức năng đặc biệt**:
    - Có thể **xuất mô hình đã huấn luyện** thông qua API `/api/export-model` → file `.joblib`.
    - Gửi mẫu dữ liệu vào API `/api/xai-explanations` để nhận lời giải thích bằng công nghệ **Explainable AI (XAI)** (ví dụ SHAP values).

PHẦN 7: PHÁT TRIỂN ỨNG DỤNG VÀ GIẢI PHÁP AI

7.1. Tổng quan

Đây là một ứng dụng web toàn diện, kết hợp ba chức năng chính vào một giao diện duy nhất:

1. **Dashboard Thời tiết:** Cung cấp thông tin thời tiết hiện tại và dự báo cho các địa điểm cụ thể, được lấy từ API bên ngoài (AccuWeather).
2. **Phân tích Dữ liệu Tương tác:** Cho phép người dùng tải lên tập dữ liệu (CSV), hoặc sử dụng dữ liệu chất lượng không khí được lấy tự động, sau đó thực hiện phân tích khám phá dữ liệu (EDA) một cách trực quan.
3. **Huấn luyện Mô hình Học máy:** Cung cấp một giao diện để người dùng có thể lựa chọn các đặc trưng (features), huấn luyện các mô hình dự báo (hồi quy) và xem kết quả đánh giá hiệu suất.

7.2 Kiến trúc Hệ thống Backend

Hệ thống backend được xây dựng bằng **Flask**. Kiến trúc được thiết kế theo dạng module hóa, giúp dễ dàng bảo trì và mở rộng.

- **`app.py` (Module lõi):** Đóng vai trò là trung tâm điều khiển. Nó định nghĩa tất cả các API endpoint, xử lý các yêu cầu HTTP từ frontend, quản lý session và điều phối hoạt động của các module khác.
- **Thư mục `build`:** Chứa file `index.html` là nơi chưa toàn bộ giao diện frontend.
- **Thư mục `utils`:** Chứa các module logic nghiệp vụ, được phân tách rõ ràng theo chức năng:
  - `weather_api.py`: Giao tiếp với AccuWeather.
  - `air_quality_data_fetch.py`: Giao tiếp với OpenWeather để lấy dữ liệu lịch sử.
  - `data_analysis.py`: Logic phân tích dữ liệu.
  - `visualization.py`: Tạo các biểu đồ trực quan.
  - `ml_models.py`: Logic huấn luyện và dự báo của mô hình học máy.
  - `negative_value_handling.py` & `outlier_handling.py`: Các tiện ích tiền xử lý dữ liệu.
  - `gemini_chatbot.py`: Tích hợp với Gemini AI.
- **Thư mục `trained_model`:** Nơi lưu trữ các mô hình đã được huấn luyện (`.joblib`) để tái sử dụng.
- **Thư mục `uploads`:** Nơi lưu trữ các file CSV do người dùng tải lên.

7.3 Phân tích các Thành phần Chính

7.3.1 Module Giao diện chính và API (`app.py`)

- **API Endpoints:** Cung cấp một loạt các API để frontend có thể tương tác, bao gồm:
  - `/api/weather/current`: Lấy dữ liệu thời tiết hiện tại.
  - `/upload-dataset`: Xử lý việc tải lên file CSV.
  - `/api/data-analysis/...`: Các API để phân tích dữ liệu, xóa cột, xử lý giá trị ngoại lệ/âm.
  - `/train-model`, `/make-prediction`: Các API cho việc huấn luyện và sử dụng mô hình ML.

    - `/api/message`: Endpoint cho chatbot, có khả năng định tuyến đến **Watson Assistant** hoặc **Gemini**.
- **Quản lý Trạng thái Dữ liệu:** Hệ thống sử dụng một cơ chế lưu trữ dataframe kép (`original` và `modified`) trong bộ nhớ. Điều này cho phép người dùng thực hiện các thao tác tiền xử lý (như xóa cột, xử lý outlier) mà không làm mất dữ liệu gốc, và có thể quay lại trạng thái ban đầu khi cần.
- **Tích hợp Chatbot:** Tích hợp linh hoạt hai trợ lý AI: IBM Watson và Google Gemini. Người dùng có thể chuyển đổi giữa hai chatbot này trên giao diện.

7.3.2 Module Thu thập Dữ liệu

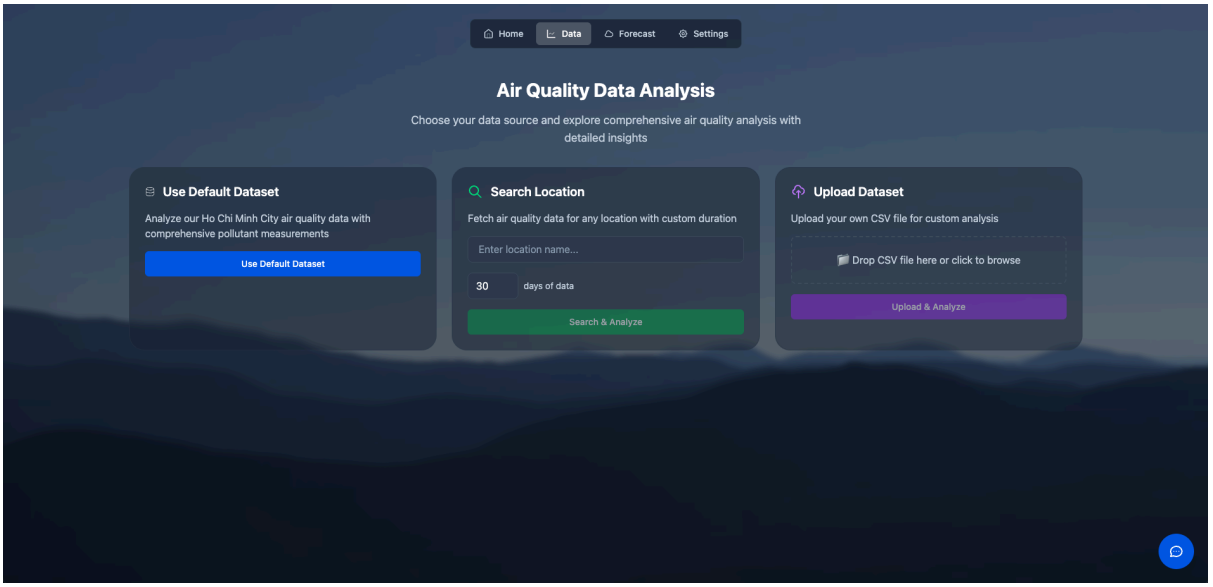
- **`weather_api.py` (AccuWeather):**
    - Chịu trách nhiệm lấy thông tin thời tiết hiện tại và dự báo 5 ngày.
    - Có chức năng `_format_current_weather_data` và `_format_forecast_data` để chuyển đổi dữ liệu thô từ API thành một cấu trúc JSON sạch, thân thiện với frontend.
    - Thực hiện một phép *ước tính* chỉ số AQI dựa trên các thông số thời tiết như tầm nhìn và độ ẩm, một giải pháp thông minh khi không có API AQI chuyên dụng.
- **`air_quality_data_fetch.py` (OpenWeather):**
    - Lấy dữ liệu **lịch sử** về các chất ô nhiễm không khí (`pm2_5`, `co`, `no2`, v.v.) cho một địa điểm và khoảng thời gian nhất định.
    - Dữ liệu này là đầu vào chính cho các chức năng phân tích và huấn luyện mô hình.
    - Sử dụng Geocoding API để chuyển đổi tên địa điểm thành tọa độ (vĩ độ, kinh độ).

7.3.3 Module Phân tích và Trực quan hóa Dữ liệu (`data_analysis.py`, `visualization.py`)

Đây là một trong những tính năng mạnh mẽ nhất của dashboard.

- **Phân tích Toàn diện (`data_analysis.py`):**
    - Class `WeatherDataAnalyzer` thực hiện một loạt các phân tích tự động: thông tin cơ bản (số dòng, cột), thống kê mô tả (trung bình, trung vị, độ lệch chuẩn), kiểm tra dữ liệu thiếu, dữ liệu trùng lặp.
    - Tự động phát hiện các cột chứa thông tin ngày giờ để tính toán khoảng thời gian của dữ liệu.
- **Trực quan hóa Đa dạng (`visualization.py`):**
    - Sử dụng **Matplotlib**, **Seaborn** và **Plotly** để tạo ra nhiều loại biểu đồ.
    - Các biểu đồ được tạo dưới dạng ảnh base64 (sử dụng Matplotlib) hoặc đối tượng JSON (sử dụng Plotly) để dễ dàng nhúng vào giao diện web.
    - Các loại biểu đồ bao gồm:
        - Biểu đồ tương quan (Correlation Heatmap).
        - Biểu đồ phân phối (Distribution Plots).
        - Biểu đồ hộp (Box Plots) để phân tích ngoại lệ.

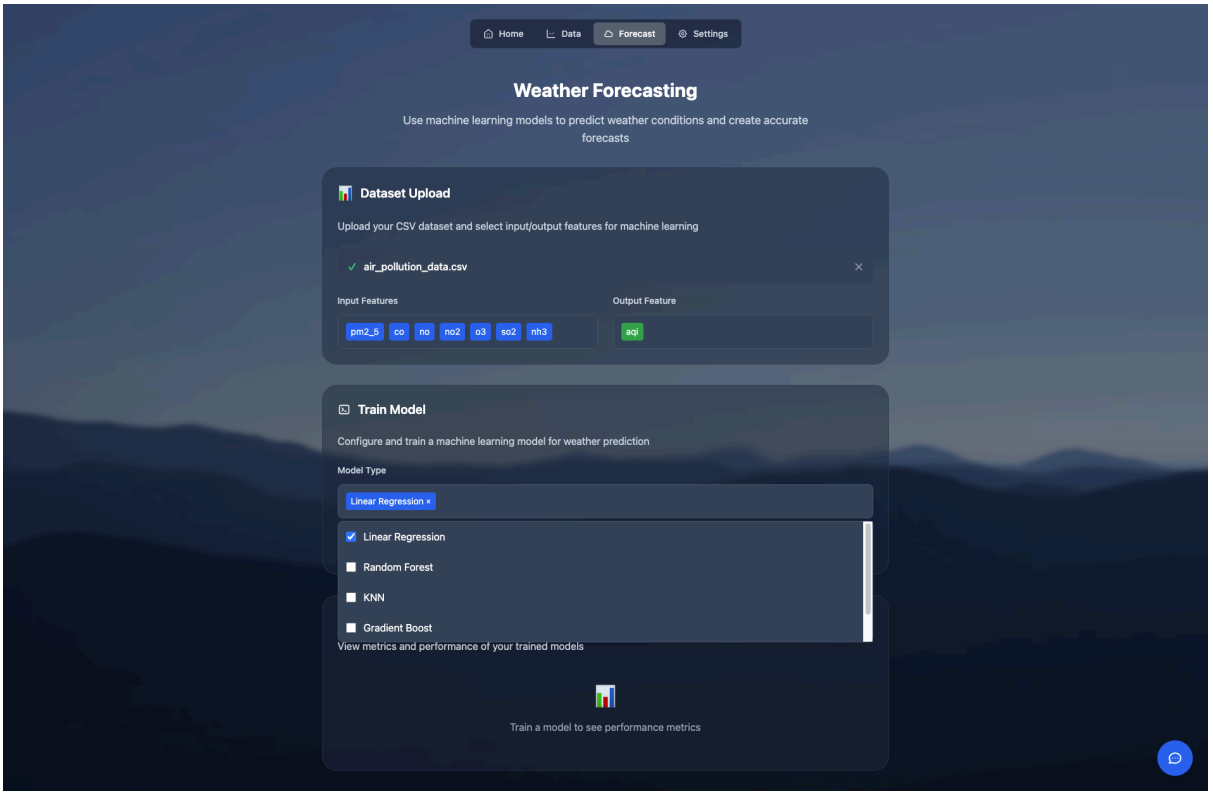
- Biểu đồ chuỗi thời gian (Time Series Plots).
- Đám mây từ (Word Cloud) từ tên các cột.



7.3.4 Module Học máy (`ml_models.py`)

Module này cung cấp một quy trình học máy hoàn chỉnh.

- **Quy trình:**
  1. **Chuẩn bị Dữ liệu:** Tự động xử lý các giá trị thiếu, mã hóa các biến phân loại (LabelEncoder) và chuẩn hóa các biến số (StandardScaler).
  2. **Lựa chọn Mô hình:** Hỗ trợ nhiều mô hình hồi quy phổ biến: `Linear Regression`, `Random Forest`, `KNN`, `Gradient Boost`.
  3. **Huấn luyện:** Huấn luyện mô hình đã chọn trên dữ liệu đã được tiền xử lý. Dữ liệu được chia thành tập huấn luyện và tập kiểm tra theo thứ tự thời gian để đảm bảo tính hợp lệ cho dữ liệu chuỗi thời gian.
  4. **Đánh giá:** Tính toán các chỉ số hiệu suất quan trọng như RMSE, MAE, và R^2.
  5. **Trực quan hóa Đánh giá:** Tạo các biểu đồ tương tác (sử dụng Plotly) như đường cong học tập (Learning Curve), biểu đồ giá trị thực tế vs. dự đoán, và biểu đồ phần dư (Residuals Plot) để người dùng có thể đánh giá sâu hơn về hiệu suất của mô hình.
  6. **Lưu trữ:** Tự động lưu mô hình đã huấn luyện, scaler, và các thông tin liên quan vào file `.joblib` để có thể tái sử dụng sau này.



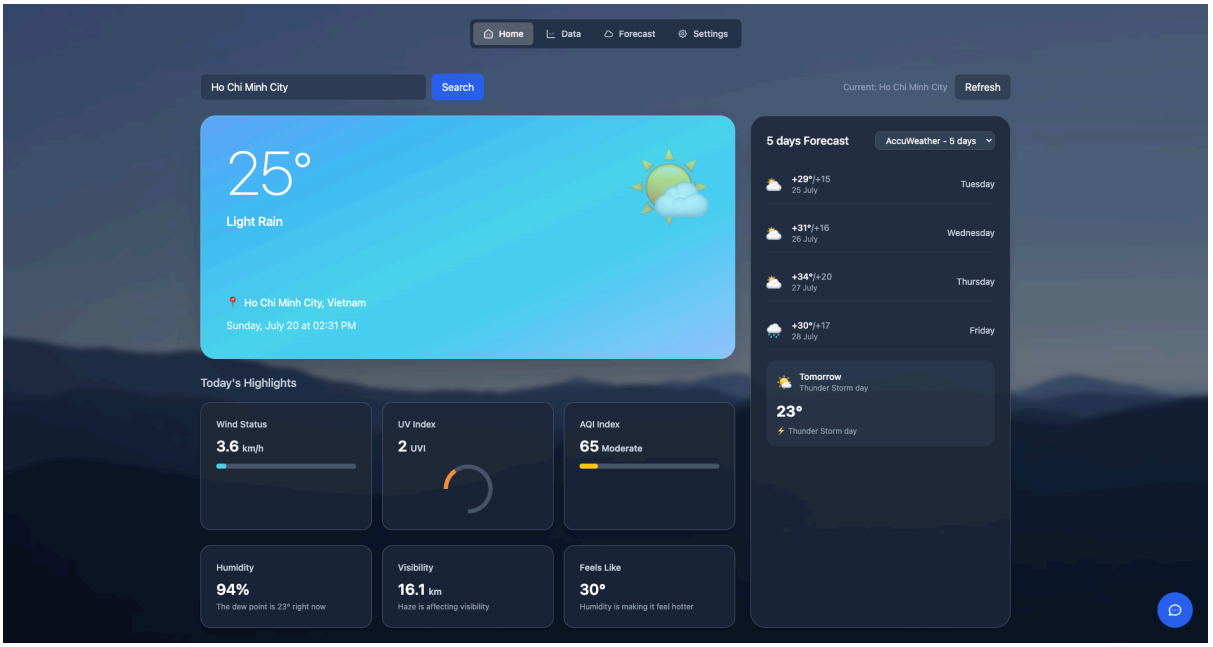
Giao diện cho phép người dùng chọn đặc trưng và mô hình để huấn luyện.

7.3.5 Module Tiền xử lý Dữ liệu

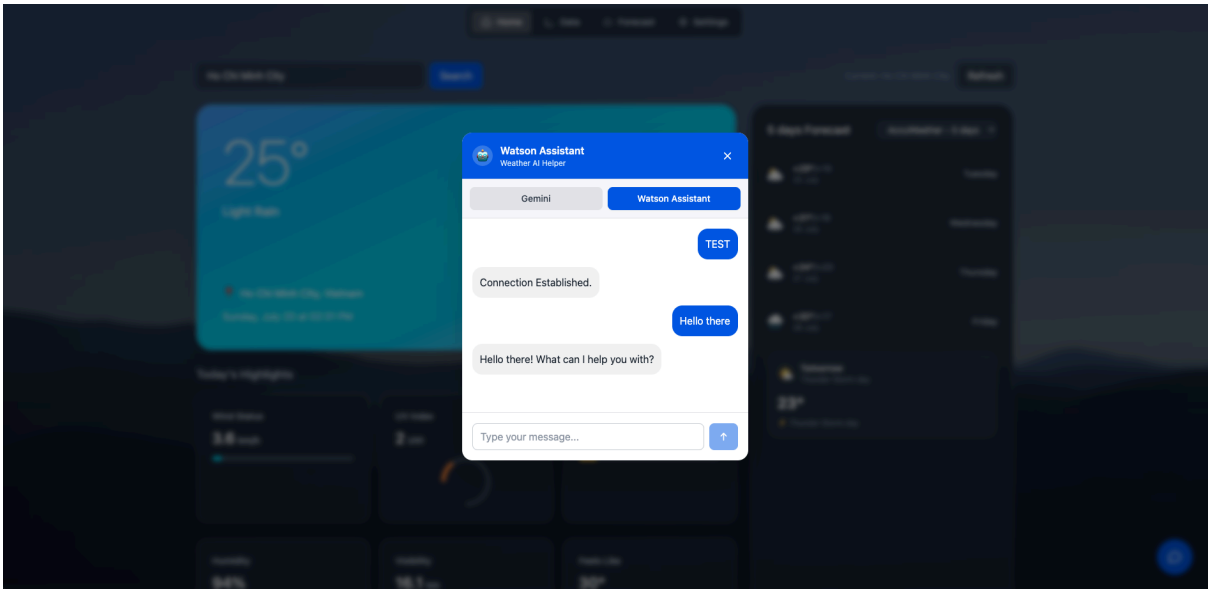
- **`negative_value_handling.py`:** Cung cấp các phương pháp để xử lý các giá trị âm không hợp lệ trong dữ liệu (ví dụ: nồng độ chất ô nhiễm không thể âm), bao gồm nội suy tuyến tính hoặc xóa bỏ dòng dữ liệu.
- **`outlier_handling.py`:** Cung cấp các kỹ thuật phổ biến để xử lý giá trị ngoại lệ, bao gồm:
    - **Capping:** Giới hạn các giá trị ngoại lệ bằng ngưỡng trên và dưới (dựa trên IQR).
    - **Transformation:** Áp dụng các phép biến đổi toán học (log, căn bậc hai) để giảm tác động của ngoại lệ.
    - **Deletion:** Xóa các hàng chứa giá trị ngoại lệ.

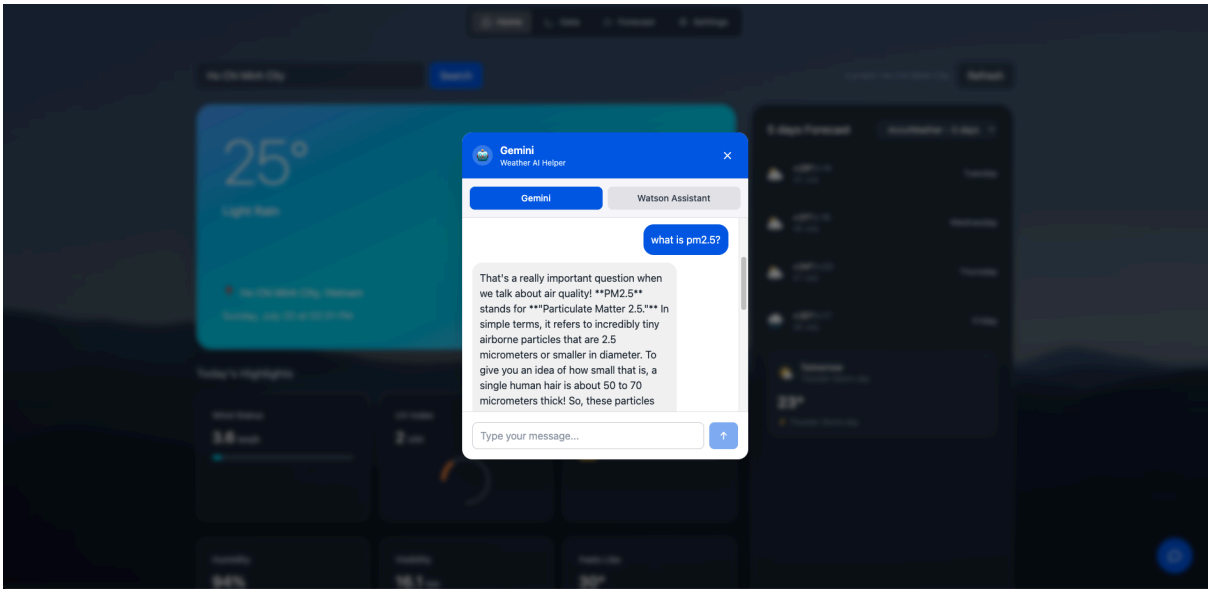
7.4. Luồng hoạt động chính

1. **Trang chủ:** Người dùng truy cập vào trang chính, thấy thông tin thời tiết của một địa điểm mặc định (TP. Hồ Chí Minh). Họ có thể tìm kiếm địa điểm khác.



2. **Phân tích Dữ liệu:** Người dùng chuyển sang tab "Data", có thể chọn phân tích dữ liệu mặc định hoặc tải lên file CSV của riêng mình. Hệ thống sẽ tự động chạy phân tích và hiển thị một loạt các biểu đồ và thống kê.
3. **Huấn luyện Mô hình:** Người dùng vào tab "Forecast". Họ tải lên dữ liệu, chọn các cột đầu vào (Input Features) và cột mục tiêu (Output Feature). Sau đó, họ chọn một mô hình từ danh sách và nhấn "Train". Kết quả huấn luyện, bao gồm các chỉ số và biểu đồ, sẽ được hiển thị.
4. **Tương tác với Chatbot:** Ở bất kỳ trang nào, người dùng có thể mở cửa sổ chatbot, chọn giữa Gemini hoặc Watson Assistant để đặt câu hỏi liên quan đến thời tiết hoặc các khái niệm khoa học dữ liệu.





KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Tóm tắt các Kết quả Chính

1. **Các "Thủ phạm" Chính:** Bụi mịn **PM2.5, PM10 và khí CO** là ba yếu tố có ảnh hưởng mạnh mẽ nhất, quyết định đến sự biến động của chỉ số AQI.
2. **Tình trạng Báo động:** Phần lớn thời gian (gần 90% số ngày), chất lượng không khí tại TP.HCM ở các mức có hại cho sức khỏe.
3. **Quy luật Thời gian:** Chất lượng không khí có quy luật biến động rõ rệt theo cả chu kỳ năm (mùa khô/mùa mưa) và chu kỳ tuần (ngày làm việc/cuối tuần).

Hạn chế của Dự án

- **Tính Đại diện của Dữ liệu:** Dữ liệu chỉ được thu thập từ một điểm duy nhất, có thể không phản ánh chính xác tình hình toàn thành phố.
- **Thiếu các Biến Ngoại sinh:** Phân tích chưa bao gồm các yếu tố quan trọng khác như dữ liệu thời tiết (hướng gió, tốc độ gió, độ ẩm, lượng mưa) hay mật độ giao thông.

Hướng phát triển Tương lai

1. **Mở rộng Mạng lưới Thu thập Dữ liệu:** Thu thập dữ liệu từ nhiều cảm biến đặt tại các vị trí khác nhau trên toàn thành phố.
2. **Tích hợp Dữ liệu Đa nguồn:** Kết hợp dữ liệu chất lượng không khí với dữ liệu thời tiết và giao thông để xây dựng mô hình phân tích và dự báo chính xác hơn.
3. **Xây dựng Mô hình Dự báo Thời gian thực:** Sử dụng các thuật toán học máy nâng cao (như LSTM, XGBoost) để xây dựng một hệ thống có khả năng dự báo chỉ số AQI.
4. **Phát triển Ứng dụng:** Xây dựng một trang web hoặc ứng dụng di động để trực quan hóa dữ liệu và cung cấp cảnh báo sớm cho người dân.

– the end –